

Harness appliqué au module FIRO B / Élément Humain

Auteur : Manus AI

Date : 8 mai 2026

1. Principe directeur

Pour ton module, le **harness** doit être compris comme le dispositif complet qui transforme un prompt sensible en **service IA fiable, contrôlé et auditable**. Le prompt reste le cœur rédactionnel, mais il ne doit pas porter seul la responsabilité de la qualité finale. Le harness encadre ce prompt par des règles de données, des contrôles métier, des garde-fous rédactionnels, une logique de validation et une traçabilité technique.

Le bon objectif n’ est pas de construire « un prompt qui écrit bien », mais un **module de restitution qui produit systématiquement un texte court, prudent, utile et conforme au cadre Élément Humain**.

Dans cette logique, ton module FIRO B doit être conçu comme une chaîne en six étapes : réception des données, validation, calcul des écarts, sélection des angles de lecture, génération encadrée, puis contrôle de la sortie avant affichage.

2. Vue d’ ensemble du harness cible

Le harness du module FIRO B peut être structuré autour de quatre couches : **entrée contrôlée, analyse déterministe, génération encadrée** et **sortie vérifiée**. Cette séparation est importante parce qu’ elle évite de demander au modèle de tout faire : calculer, choisir, interpréter, rédiger et se contrôler lui-même.

Couche	Responsabilité	Ce qui doit être fait hors modèle	Ce que le modèle doit faire
Entrée contrôlée	Garantir que les données sont complètes et exploitables.	Vérifier les scores, les bornes, les champs manquants et le format.	Rien. Le modèle ne doit pas deviner les données.
Analyse déterministe	Calculer les écarts et choisir les dimensions pertinentes.	Calculer I_e/I_w , C_e/C_w , O_e/O_w , comparer avec les feedbacks et prioriser.	S’ appuyer sur les dimensions déjà sélectionnées.

Génération encadrée	Produire la restitution courte selon une structure stable.	Injecter uniquement les données nécessaires dans le prompt.	Rédiger avec prudence, sobriété et hypothèses.
Sortie vérifiée	Contrôler que le texte respecte les interdits.	Vérifier longueur, formulations interdites, structure, ton et nombre de questions.	Éventuellement régénérer si une règle échoue.

3. Flux fonctionnel recommandé

Le flux recommandé commence par la réception des données depuis le site ou depuis un outil d'administration. Ces données ne doivent pas être envoyées directement au modèle. Elles doivent d'abord être normalisées par le backend afin de garantir une interprétation stable.

Ensuite, le backend calcule les écarts entre scores exprimés et désirés, puis les écarts éventuels entre auto-perception et feedback des pairs. À ce stade, le système sélectionne au maximum deux dimensions comportementales prioritaires parmi Inclusion, Contrôle et Ouverture. La transparence peut être traitée à part, de manière systématique, mais courte.

Étape	Nom	Description	Résultat attendu
1	Réception	Le site transmet les scores et feedbacks structurés.	Objet JSON complet.
2	Validation	Le backend vérifie la présence, le type et les bornes des valeurs.	Données acceptées ou erreur explicite.
3	Calcul	Le backend calcule les écarts exprimé/désiré et auto/feedback.	Liste d'écarts normalisés.
4	Priorisation	Le backend choisit les dimensions à traiter.	Maximum deux dimensions + transparence.

5	Génération	Le modèle reçoit un prompt strict et des données filtrées.	Restitution courte rédigée.
6	Validation sortie	Le harness contrôle le texte généré.	Texte validé, corrigé ou régénéré.
7	Traçabilité	Le système journalise les métadonnées.	Version prompt, modèle, date, statut qualité.

4. Règles métier à rendre déterministes

Le document initial mentionne les écarts forts, les tensions clés et les feedbacks pairs. Pour un usage en production, ces notions doivent devenir des règles explicites. Le modèle ne doit pas décider seul ce qui est « fort » ou « pertinent ».

Je recommande de définir une règle simple pour la première version : une dimension est candidate si l' écart absolu entre exprimé et désiré est supérieur ou égal à deux, ou si l' écart entre auto-perception et feedback des pairs est supérieur ou égal à deux. Ensuite, si plus de deux dimensions sont candidates, le système retient les deux dimensions ayant l' intensité d' écart la plus forte.

Règle	Définition recommandée	Décision du harness
Écart exprimé/désiré significatif	<code>abs(score_exprimé - score_désiré) >= 2</code>	Dimension candidate.
Écart auto/feedback significatif	<code>abs(score_exprimé - feedback_pairs) >= 2</code>	Dimension candidate.
Trop de dimensions candidates	Plus de deux dimensions Inclusion/Contrôle/Ouverture ressortent.	Garder les deux plus fortes.
Aucune dimension candidate	Aucun écart ne dépasse le seuil.	Produire une restitution prudente centrée sur l' équilibre apparent.
Transparence	Score traité séparément.	Commentaire bref, non diagnostique, toujours contextualisé.

5. Schéma d' entrée recommandé

L' entrée du module doit être un objet strict. C' est un point important : plus l' entrée est structurée, moins le modèle a besoin d' interpréter. Le backend peut ensuite transformer cet objet brut en un objet « prêt pour génération ».

JSON

```
{
  "module": "firo_b_short_restitution",
  "language": "fr",
  "participant_id": "optional_internal_id",
  "scores": {
    "inclusion": {
      "expressed": 4,
      "wanted": 7,
      "peer_feedback": 5
    },
    "control": {
      "expressed": 6,
      "wanted": 3,
      "peer_feedback": 6
    },
    "openness": {
      "expressed": 2,
      "wanted": 6,
      "peer_feedback": 3
    },
    "transparency": {
      "score": 4
    }
  },
  "generation_rules": {
    "max_words": 650,
    "min_gap": 2,
    "max_behavioral_dimensions": 2,
    "output_sections": [
      "lecture_synthetique",
      "point_de_cadre",
      "points_cles",
      "lecture_manageriale",
      "pistes_de_reflexion"
    ]
  }
}
```

Ce format permet de dissocier les données brutes, les règles de génération et les contraintes de sortie. Il facilite aussi les tests, le versioning et l'audit.

6. Objet intermédiaire transmis au modèle

Le modèle ne devrait pas recevoir toutes les données brutes si ce n'est pas nécessaire. Le harness peut calculer et filtrer en amont, puis transmettre uniquement une synthèse contrôlée.

JSON

```
{
  "selected_dimensions": [
    {
      "name": "inclusion",
      "reason": "ecart_exprime_desire",
      "expressed": 4,
      "wanted": 7,
      "gap": 3,
      "interpretation_instruction": "Formuler une hypothèse sur un possible éca
    },
    {
      "name": "openness",
      "reason": "ecart_exprime_desire",
      "expressed": 2,
      "wanted": 6,
      "gap": 4,
      "interpretation_instruction": "Formuler une hypothèse sur un possible éca
    }
  ],
  "transparency": {
    "score": 4,
    "instruction": "Commenter brièvement la transparence sans conclure sur la p
  },
  "style_constraints": {
    "tone": "professionnel, neutre, sobre",
    "max_words": 650,
    "forbidden_phrases": [
      "tu es",
      "vous êtes",
      "ta personnalité",
      "votre personnalité",
      "diagnostic"
    ],
    "required_hypothesis_markers": [
      "pourrait suggérer",
      "peut inviter à explorer",
```

```
    "peut indiquer dans ce contexte"  
  ]  
}  
}
```

Cette approche réduit le risque que le modèle commente des dimensions non pertinentes ou extrapole à partir de scores isolés.

7. Prompt système recommandé

Le prompt système doit rester stable et contenir les règles non négociables. Il ne doit pas contenir les données variables du participant. Ces données seront injectées dans un bloc séparé.

Plain Text

Tu es un praticien certifié de l'Élément Humain selon William Schutz. Tu produis

Règles impératives :

- Tu ne juges jamais les scores.
- Tu ne fais aucun diagnostic de personnalité.
- Tu ne présentes jamais les résultats comme une identité.
- Tu rappelles que les scores reflètent des comportements dans un contexte donné.
- Tu formules uniquement des hypothèses.
- Tu utilises des formulations prudentes comme : « pourrait suggérer », « peut-être ».
- Tu n'emploies jamais les formulations : « tu es », « vous êtes », « ta personnalité ».
- Tu restes sobre, clair et synthétique.
- Tu ne dépasses pas 650 mots.

Structure obligatoire :

1. Lecture synthétique – 5 lignes maximum.
2. Point de cadre – 3 lignes maximum.
3. Points clés de lecture – uniquement les dimensions fournies dans les données.
4. Lecture managériale – 3 lignes maximum, formulée en hypothèses.
5. Pistes de réflexion – 3 à 5 questions ouvertes, simples et non confrontantes.

Objectif : produire une restitution claire et utile, qui ouvre la réflexion sans

8. Prompt utilisateur généré par le harness

Le prompt utilisateur doit être produit automatiquement par le backend. Il contient les dimensions sélectionnées et les contraintes applicables à cette génération précise.

Plain Text

À partir des données structurées ci-dessous, rédige la restitution courte demandée.

Données à commenter :
{{selected_dimensions_json}}

Transparence :
{{transparency_json}}

Contraintes spécifiques :

- Ne commente aucune dimension absente des données fournies.
- Ne propose pas plus de 5 questions finales.
- Ne fais aucune recommandation comportementale directive.
- Ne transforme pas les hypothèses en conclusions.
- Si les tensions semblent faibles, reste prudent et souligne l'intérêt d'explorer.

Cette séparation entre prompt système et prompt utilisateur est utile pour maintenir une gouvernance claire : le cadre ne change pas à chaque génération, seules les données injectées changent.

9. Valideur de sortie

Le valideur de sortie est une pièce centrale du harness. Il agit après la génération, avant affichage à l'utilisateur. Son rôle est de refuser une restitution qui ne respecte pas les contraintes essentielles.

Contrôle	Méthode simple	Action si échec
Longueur	Compter les mots.	Régénérer avec instruction de réduction.
Structure	Vérifier les cinq sections attendues.	Régénérer ou reformater.
Formulations interdites	Recherche de chaînes comme « tu es », « vous êtes ».	Rejeter et régénérer.
Ton hypothétique	Vérifier la présence de marqueurs prudents.	Régénérer avec rappel de prudence.
Dimensions non autorisées	Comparer les dimensions citées avec les dimensions sélectionnées.	Rejeter si une dimension non fournie est analysée.
Questions finales	Compter les points d'interrogation dans la section finale.	Réduire à 3–5 questions.

En première version, ces contrôles peuvent être réalisés par règles simples. Dans une version plus avancée, on peut ajouter un second appel IA de type « critique conformité », mais il ne doit pas remplacer les contrôles déterministes.

10. Stratégie de régénération

Le harness doit prévoir ce qui se passe lorsqu' une sortie n' est pas conforme. Il ne faut pas afficher une restitution problématique en production. Il est préférable de définir un mécanisme de régénération limité.

Situation	Réponse du harness
Échec mineur, par exemple texte trop long	Régénération avec demande de raccourcissement.
Formulation interdite	Régénération complète avec rappel explicite des interdits.
Dimension non autorisée commentée	Régénération complète en réinjectant les dimensions autorisées.
Deuxième échec consécutif	Basculer vers un modèle alternatif ou envoyer en revue humaine.
Troisième échec	Ne pas afficher ; journaliser l' incident et afficher un message neutre.

Cette stratégie protège la qualité du service et évite qu' un défaut de génération devienne une erreur visible pour le participant.

11. Architecture AWS cible

Dans une infrastructure AWS, le harness doit être porté principalement par le backend. Le frontend ne doit pas contenir de clé modèle, ne doit pas appeler directement le fournisseur IA et ne doit pas décider seul des règles métier.

Composant	Service AWS possible	Rôle dans le harness
Site frontend	S3 + CloudFront ou AWS Amplify	Interface utilisateur et affichage des restitutions.

API	API Gateway	Point d'entrée sécurisé pour les demandes de génération.
Logique harness	AWS Lambda ou ECS Fargate	Validation, calculs, sélection des dimensions, génération du prompt.
Modèle IA	Amazon Bedrock ou API externe encapsulée	Génération du texte.
Stockage applicatif	DynamoDB ou Aurora Serverless	Sessions, versions de prompt, statuts de génération.
Secrets	AWS Secrets Manager	Clés API, paramètres sensibles, secrets d'intégration.
Chiffrement	AWS KMS	Chiffrement des données sensibles.
Logs et audit	CloudWatch + CloudTrail	Traçabilité technique et supervision.
Protection web	AWS WAF	Protection des endpoints exposés.

Le point clé est que le harness doit être **centralisé côté serveur**. Le frontend peut déclencher une restitution, mais il ne doit pas construire lui-même la logique de sélection des dimensions ou les prompts complets.

12. Données à journaliser

La journalisation ne doit pas consister à tout stocker sans discernement. Il faut conserver ce qui permet l'audit et l'amélioration continue, tout en minimisant les données sensibles.

Donnée	À stocker ?	Commentaire
Version du prompt système	Oui	Indispensable pour comprendre une restitution.
Version des règles métier	Oui	Permet d'expliquer la sélection des dimensions.
Modèle utilisé	Oui	Utile pour audit qualité et comparaison.

Scores bruts	Selon politique de confidentialité	À minimiser ou pseudonymiser si possible.
Restitution générée	Selon besoin produit	À chiffrer si conservée.
Logs techniques	Oui	Sans données personnelles inutiles.
Feedback utilisateur	Oui, si consenti	Très utile pour amélioration qualité.

13. Banc de test recommandé

Avant production, le module doit être testé sur une série de profils types. Ces profils ne doivent pas forcément représenter des personnes réelles ; ils servent à tester les comportements du harness.

Cas test	Objectif du test	Résultat attendu
Aucun écart significatif	Vérifier que le modèle ne force pas une tension.	Restitution prudente et non surinterprétative.
Fort écart inclusion	Vérifier la capacité à parler de place relationnelle sans jugement.	Hypothèse claire, courte, contextualisée.
Fort écart contrôle	Vérifier l'absence de jugement sur le leadership ou le besoin de cadre.	Formulation neutre et managériale.
Fort écart ouverture	Vérifier la prudence sur la proximité et l'expression de soi.	Pas d'interprétation psychologique.
Feedback pairs divergent	Vérifier la lecture auto/feedback.	Hypothèse sur l'écart de perception, sans conclusion.
Trois dimensions candidates	Vérifier la priorisation.	Deux dimensions seulement sont traitées.
Sortie trop longue	Vérifier le validateur.	Régénération automatique.

14. Version minimale viable du harness

Pour une première version, il n’ est pas nécessaire de construire un système trop complexe. Je recommanderais une version minimale mais sérieuse, composée de six éléments.

Élément MVP	Décision recommandée
Schéma JSON d’ entrée	Obligatoire dès la V1.
Calcul des écarts côté backend	Obligatoire dès la V1.
Sélection de deux dimensions maximum	Obligatoire dès la V1.
Prompt système versionné	Obligatoire dès la V1.
Valdateur de sortie simple	Obligatoire dès la V1.
Journalisation minimale	Version prompt, modèle, statut qualité, horodatage.

Cette V1 permettra déjà de produire un module beaucoup plus robuste qu’ un simple prompt appelé depuis une page web.

15. Formule courte à retenir

Le harness de ton module peut être résumé ainsi :

Données validées → écarts calculés → dimensions sélectionnées → prompt injecté → restitution générée → sortie contrôlée → résultat tracé.

C’ est cette chaîne qui fait passer ton module d’ une logique artisanale à une logique de service professionnel. Le prompt reste essentiel, mais il devient une pièce d’ un système plus fiable, plus sobre et plus maîtrisé.

16. Prochaine étape recommandée

La prochaine étape concrète consiste à rédiger une **spécification technique V1** utilisable par un développeur. Elle devrait contenir les endpoints API, le schéma JSON définitif, les règles de calcul, le prompt système versionné, les contrôles de sortie et les règles de stockage AWS. Une fois cette spécification validée, le développement du module pourra commencer sur des bases beaucoup plus sûres.